

저시력자를 위한 온디바이스 키오스크 이용 가이드 시스템 개발

최재우*, 김민경**, 김수현**, 김은혁**, 이정빈**, 정현수**, 홍석준**, 이한용***

Development of On-Device Kiosk Use Guide System for People With Low Vision

JaeWoo Choi*, MinKyung Kim**, SooHyun kim**, EunHyuk Kim**, JeongBin Lee**,
HyunSu Jung**, SukJun Hong**, HanYong Lee***

요 약

본 연구는 키오스크 확산으로 인한 고령 저시력자의 사회적 고립 문제를 해소하기 위해 온디바이스 (On-device) 기반 접근성 가이드 시스템을 개발한다. 본 시스템은 음성 및 햅틱(촉각) 피드백을 결합한 멀티모달 인터페이스를 통해 다양한 환경에서 안정적인 조작 가이드를 제공한다. 좌표 매칭 알고리즘을 이용한 핸드 트래킹 기반 위치 유도 기능을 통해 사용자는 목표물의 위치를 주도적으로 파악한다. 이는 기존 물리적 인프라 교체 없이 고령 저시력자의 자립성을 제고하고 디지털 소외를 완화하는데 기여할 것으로 기대된다.

Abstract

This study develops an on-device accessibility guidance system to address the social isolation experienced by elderly people with low vision due to the widespread adoption of kiosks. The proposed system provides reliable interaction guidance in various environments through a multimodal interface that integrates voice and haptic (tactile) feedback. Using a coordinate-matching algorithm, a hand-tracking-based localization feature enables users to actively perceive the position of target objects. This approach is expected to enhance the independence of elderly users with low vision and alleviate digital exclusion without requiring modifications to existing physical infrastructure.

Key words

On-device AI, Coordinate Matching, Haptic Feedback, Real-time Interface, Proactive Location Guidance

*경기대학교 AI컴퓨터공학부, cistus75@kyonggi.ac.kr (교신저자)

**경기대학교 AI컴퓨터공학부, kbk3038, 202211422, ecj3love1, wjdqls014, dalyam, hsj030426@kyonggi.ac.kr

*** 경기대학교 AI 컴퓨터공학부 교수 caehyl210@kyonggi.ac.kr

※본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학지원사업의 연구결과로 수행되었음 (2021-0-01393)

I. 서 론

현대 사회에선 초고령 사회로의 진입과 함께 중·장년층 및 노년층에서 시각 기능 저하 사례가 지속적으로 증가하는 추세를 보인다. 또한 연령이 증가할수록 디지털 기기 활용 능력이 낮아지는 경향이 키오스크의 보급이 확산되는 현재 상황과 맞물려 저시력자를 포함한 정보 취약계층에게 새로운 장벽으로 작용하고 있다[1].

저시력자를 위한 편의기능의 부족으로 무인정보단말기 이용에 어려움을 겪은 비율은 77.1%이다. 뿐만 아니라 무인정보단말기의 조작의 어려움으로 인해 주문이 늦어져 뒤에서 기다리는 사람의 눈치가 보이는 점(54%), 버튼 위치를 찾기 어렵거나 메뉴 선택 방법 및 이동의 어려움(26.1%) 등 역시 존재한다[2]. 특히 주문 지연으로 인한 심리적 부담과 주변 시선에 대한 압박은 이용 기피로 이어지는데, 이는 단순한 불편을 넘어 사회적 고립과 디지털 소외를 심화시키는 요인으로 작용한다.

본 연구는 키오스크 확산으로 인한 고령 저시력자의 사회적 고립 문제를 해소하기 위해 독립적인 환경에서 작동하는 온디바이스(On-device) 기반 접근성 가이드 시스템을 개발한다. 본 시스템은 음성 및 햅틱(촉각) 피드백을 결합한 멀티모달 인터페이스를 통해 다양한 환경에서 안정적인 조작 가이드를 제공한다. 좌표 매칭 알고리즘을 이용한 핸드 트래킹 기반 위치 유도 기능을 통해 사용자는 목표물의 위치를 주도적으로 파악한다.

II. 배경 지식

본 연구의 목적을 달성하기 위해 다음과 같은 환경을 구축한다. 실제 배포되는 모바일 환경의 제한된 리소스로 인하여 경량화가 필요함에 따라 TFLite 프레임 워크를 통한 모델 양자화로 추론 속도 및 메모리 점유율을 최적화한다[3]. UI 컴포넌트의 실시간 탐지를 위하여 Anchor-free 구조로 비정형 형태 탐지에 효과적이며 PyTorch 표준인 YOLOv8 라이브러리를 활용한다[4]. 특히 그 중에서도 모바일 환경에 최적화된 경량화 모델인 Nano 버

전을 활용하여 모바일 환경에서도 안정적인 성능을 가진다. 사용자의 손가락 위치를 인식하기 위해 MediaPipe를 활용한다. 이는 카메라를 통해 손의 랜드마크를 추출하는 라이브러리로, 카메라를 통해 정교하게 위치를 추적하여 손가락의 좌표를 구해 실제 조작 범위를 구하는데 활용된다. 또한 저시력자에게 정확한 정보를 제공하기 위해 청각 및 촉각 정보를 결합한 멀티모달 피드백을 활용한다. 이는 저시력자라는 시각 정보가 제한된 특수한 환경에서 음성과 햅틱 패턴을 결합해 목표와의 방향과 거리를 복합적으로 피드백함으로써 사용자가 능동적으로 조작을 수행할 수 있도록 하는 가이드 역할을 한다.

III. 제안 알고리즘

제안하는 시스템은 4개의 핵심 모듈이 모바일 환경에서 각자 기기 내부에서 독립적으로 처리된다. 시스템의 구성요소는 YOLOv8 Nano 기반의 UI 컴포넌트 탐지 모듈, MediaPipe 기반의 Hand Tracking 모듈, UI 컴포넌트 탐지로 생성되는 정적 맵과 손가락 좌표 계산 알고리즘, 방향 및 거리 기반의 Multimodal Feedback 모듈로 총 4개며, 이들은 외부 환경 변수의 영향을 받지 않고 작동할 수 있도록 서버를 거치지 않고 독립적으로 기기 내부에서 처리된다. 특히 제한된 기기 성능으로 인해 연산량을 최소화하고자 UI 컴포넌트 탐지 모듈은 TFLite를 적용하였다. 본 논문에서는 시스템의 핵심적인 중추로 기능하는 UI 컴포넌트 탐지에 집중하여 YOLOv8 Nano 기반 모델의 학습 및 TFLite INT8 양자화 이후의 경량화된 모델의 성능에 집중하고, 나머지 모듈의 통합 및 성능 평가는 추후 연구에서 수행될 예정이다.

3.1 Hand Tracking 모듈

MediaPipe는 손에서 21개의 랜드마크를 검출하며, 이 중 검지 손가락 끝의 정규화 좌표를 추출한다. 추출된 정규화 좌표 $P_{finger} = (x_{norm}, y_{norm})$ 을 실제 화면 해상도(W, H)에 매핑하면 카메라 좌표 P_{cam} 은 다음과 같이 산출된다.

$$P_{cam} = (x_{norm} \times W, y_{norm} \times H) \quad (1)$$

3.2 좌표 매칭 알고리즘

추출된 카메라 좌표 d_i 와 정적 맵에 사전 등록된 n 개의 UI 컴포넌트 중심 좌표 $m_i = (m_{x_i}, m_{y_i})$ 의 거리를 유클리드 거리 기반으로 다음과 같이 계산한다.

$$\hat{M} = \operatorname{argmin}_i d_i \quad (2)$$

$$d_i = \sqrt{(x_{cam} - m_{x_i})^2 + (y_{cam} - m_{y_i})^2} \quad (3)$$

이 공식에 따라 거리가 가장 가까운 컴포넌트를 현재 사용자가 가리키는 대상으로 판단한다.

3.3 Multimodal Feedback 제어 모듈

최근점 컴포넌트의 거리 d 에 따라 피드백 강도를 로그 스케일 기반으로 제어한다.

$$F(d) = F_{\max} \times \frac{1 - \log(d + 1)}{\log(d_{\max} + 1)} \quad (4)$$

여기서 $d_{\max}$ 은 피드백이 활성화되는 최대 거리 임계값이며, 거리가 0에 수렴할수록 피드백 강도가 $F_{\max}$ 에 근접한다. 지수함수 대비 근거리에서의 급격한 강도 변화를 억제하여 사용자 피드백이 부드럽게 증가하도록 설계하였다.

IV. 실험 결과 및 분석

4.1 실험 환경

본 모델의 학습 환경은 AMD Ryzen 7800X3D CPU, NVIDIA GeForce RTX 4070ti GPU(12GB VRAM), 32GB RAM이라는 하드웨어 환경으로 구성하였다. 또한 Windows 11 OS를 기반으로 Python 3.12.8, PyTorch 2.7.1(CUDA 11.8), YOLOv8 v8.4.46의 소프트웨어 환경에서 모델을 학습시켰다. 학습된

모델은 TensorFlow 2.19.0을 활용하여 TFLite INT8 형식으로 양자화 변환 과정을 거친 뒤 동일한 하드웨어 환경에서 성능 평가를 진행하였다.

4.2 데이터셋 구성

본 연구에서는 빛 반사, 흔들림, 화각 등의 외부 변수에 대하여 모델의 일반화 성능을 향상시키고자 원본 UI의 디지털 데이터 및 노이즈가 포함된 실제 촬영을 통한 환경 데이터를 통합해 학습 데이터셋을 구성하였다. 특히 실제 환경 데이터의 비중을 높게 설정함으로써 모델의 강건성을 확보했다.

4.3 모델 성능 분석




그림 1. F1-신뢰도 곡선

Fig. 1. F1-Confidence Curve

그림 1에서 확인할 수 있듯 신뢰도 0.8의 구간까지 모든 클래스의 F1 스코어가 안정적으로 높게 유지되었다. 또한 신뢰도 0.448 구간에서 최대 F1 스코어 0.97을 달성하여 낮은 신뢰도에서도 높은 점수를 얻었으나, 키오스크의 특성상 오탐지로 인해 잘못된 가이드를 제공하는 경우가 치명적으로 작용하기에 이를 방지하고자 실제 시스템의 임계값을 0.7로 보수적으로 설정하여 안정성을 확보하였다.




그림 2. 정밀도-재현율 곡선
Fig. 2. Precision-Recall Curve

그림 2는 클래스별 정밀도-재현율 곡선을 의미한다. 모델은 mAP@0.5 기준으로 0.987을 달성하여 우수한 성능을 보였다. 그래프를 상세하게 관찰하면 menu_name, menu_price, category_tab의 3개의 클래스는 텍스트 위주라는 특성으로 인하여 탐지 난이도가 높아 0.4 구간부터 평균 이하의 결과를 보이나, 나머지 클래스들은 재현율이 0.9 구간에 도달하기 전까지 정밀도가 1.0에 근접하게 유지되는 안정성을 보인다.




그림 3. 정규화 혼동 행렬
Fig. 3. Normalized Confusion Matrix

그림 3에서 확인할 수 있듯 모델은 대부분의 클래스에서 0.97 이상의 높은 분류율을 달성하였다. 다만 앞서 서술한 것처럼 menu_name, menu_price

클래스의 경우 텍스트를 기반으로 하는 UI 컴포넌트라는 특성으로 인하여 배경으로의 오탐지율이 동일하게 0.13으로 나타났다. 이처럼 다른 클래스 대비 상대적으로 높게 나타난 까닭은 이 두 클래스가 가진 명확한 경계를 보유하지 않는다는 특성의 영향으로 사료된다.

이러한 모델의 실제 성능은 그림 4에서 확인할 수 있다. 이미지 속 복잡한 UI 구성에도 불구하고 모델은 팝업창, 옵션 버튼 등의 UI를 높은 신뢰도로 탐지하는 것을 확인할 수 있다. 이는 앞서 서술한 높은 정량적 지표의 유효성을 시사한다.




그림 4. 실제 UI 컴포넌트 탐지 결과
Fig. 4. Actual UI Component Detection Results

4.4 양자화 전후 성능 비교

그림 5는 PyTorch(FP32)을 기반으로 하는 원본 모델과 TFLite INT8를 통해 양자화 변환한 모델의 성능을 비교한 그래프이다. 그래프에서 확인할 수

있듯 양자화 적용 후 모델 용량은 6.2mb에서 3.2mb로 감소하였고, 추론 속도는 78.4ms에서 29.9ms로 향상되었다. 반면 mAP@0.5 점수는 98.7%에서 98.6%으로 단 0.1%p의 감소를 보인다. 이는 경량화된 모델이 기존 모델의 정확도를 거의 완벽하게 유지하면서도 모바일 환경에 적합성을 가짐을 의미한다. 모델 크기와 속도 측면에서 약 2배의 성능 향상을 달성하면서도 정확도를 사실상 유지했다는 측면에서 INT 8 양자화가 온디바이스용 AI 최적화에 효율적인 기법임을 입증한다.

자의 디지털 소외를 완화하고자 환경에 구애받지 않는 온디바이스 AI 키오스크 가이드 시스템을 제안하였다. YOLOv8 모델 기반의 UI 탐지 모델은 mAP@0.5 기준 0.987의 높은 정확도를 달성하였다. 제한된 리소스로 인하여 경량화한 모델은 0.1%p의 정확도를 대가로 48%의 모델 용량 감소와 62%의 추론 속도 향상을 이루었다.

향후 연구에서는 다양한 키오스크 UI 데이터셋을 확충하고 추가적인 학습을 통해 모델의 일반화 성능을 개선하는 것을 목표로 한다. 또한 나머지 전체




그림 5. 양자화 전후 모델 성능 비교

Fig. 5. Comparison of Model Performance Before and After Quantization

4.5 한계점

본 연구에서 제안한 시스템은 정량화된 지표를 통해 알 수 있듯 유의미한 성능을 달성하였다. 다만 텍스트 기반 UI 컴포넌트 클래스에 한정하여 배경 오탐지율이 일반 클래스에 비하여 상대적으로 높게 측정되었다. 또한 특정 키오스크에 국한된 학습 데이터로 인한 일반화 성능의 한계를 가지며, 실제 모바일 기기가 아닌 PC 환경의 속도 측정의 한계점 역시 가지고 있다.

모듈들을 통합하여 모바일 환경에 배포함으로써 타겟 사용자층의 테스트를 통해 시스템의 완성도를 높이하고자 한다.

참고문헌

- [1] 한국지능정보사회진흥원, <2025 디지털정보격차 실태조사 보고서>, 2026.03.27
- [2] 보건복지부, <2024년 장애인차별금지법 이행 실태조사>, 2025.08.08

V. 결 론

본 연구에서는 최근 증가하는 고령층 및 저시력

- [3] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, D. Kalenichenko, "Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference," in Proc. IEEE/CVF CVPR, 2018, pp. 2704-2713.

- [4] G. Jocher, A. Chaurasia, J. Qiu, "Ultralytics YOLO," GitHub, [Available Online], (Accessed 2023) <https://github.com/ultralytics/ultralytics>